

Klasyfikacja stanów EEG z wykorzystaniem sieci neuronowej, kalibracji i XAI

1. Cel projektu

Celem projektu jest zbudowanie klasyfikatora wieloklasowego, który na podstawie 178 kolejnych punktów sygnału EEG przewiduje jedną z pięciu klas stanu EEG. Projekt obejmuje cleaning, EDA, trening sieci neuronowej w PyTorch Lightning, optymalizację hiperparametrów, kalibrację prawdopodobieństw, analizę niepewności oraz wyjaśnialność z wykorzystaniem PFI i LIME.

2. Dane i przygotowanie

Wykorzystano zbiór Epileptic Seizure Recognition:

- liczba próbek: 11 500,
- liczba cech: 178,
- liczba klas: 5,
- rozkład klas: po 2300 próbek w każdej klasie,
- braki danych: 0,
- duplikaty: 0.

Usunięto kolumnę identyfikacyjną Unnamed. Target y został przekodowany z zakresu 1-5 na zakres 0-4. Dane podzielono stratyfikowanie na train/validation/test w proporcji 70/15/15. Standaryzator dopasowano tylko na zbiorze treningowym. Dodatkowo ekstremalne wartości zostały przycięte według kwantyli 0.001 i 0.999 wyznaczonych na train, aby ograniczyć wpływ outlierów bez usuwania próbek.

3. EDA

Wygenerowano:

- rozkład klas: outputs/figures/class_distribution.png,
- przykładowe sygnały dla klas: outputs/figures/example_signals.png,
- średnie sygnały klas: outputs/figures/mean_signals.png,
- energie sygnału według klasy: outputs/figures/signal_energy_by_class.png,
- wizualizacje PCA: outputs/figures/pca_train.png.

EDA pokazuje, że klasy są idealnie zbalansowane, a sygnały klasy napadowej wyróżniają się amplitudą i kształtem. Klasy 2 i 3 są bardziej podobne, co później widać w macierzy pomylek.

4. Model i trening

Model główny to MLP w PyTorch Lightning:

178 wejść
Linear + BatchNorm + ReLU + Dropout
Linear + BatchNorm + ReLU + Dropout
Linear + BatchNorm + ReLU + Dropout
Linear -> 5 klas

Optimalizacja hiperparametrow została wykonana przez Optuna. Najlepsza konfiguracja:

```
{  
  "dropout": 0.2,  
  "learning_rate": 0.0001749661369974354,  
  "weight_decay": 0.00024445012556986674,  
  "hidden_dims": [512, 256, 128]  
}
```

5. Wyniki

Metryki testowe po temperature scaling:

Metryka	Wartosc
accuracy	0.720
balanced accuracy	0.720
macro F1	0.718
weighted F1	0.718
macro OVR AUROC	0.939
NLL	0.601
Brier score	0.356
ECE	0.031

Najlepsze wyniki osiągnięto dla klasy `epileptic_seizure`: F1 = 0.954.

Najslabsze wyniki wystąpiły dla klasy `tumor_area_eeg`: F1 = 0.509. Model często myli klasy 2 i 3, co jest spodziewane, ponieważ obie dotyczą zapisów związanych z pacjentami z guzem, ale różnych obszarów.

6. Kalibracja prawdopodobieństw

Zastosowano temperature scaling dopasowany na zbiorze walidacyjnym. Wyznaczona temperatura wyniosła ok. 1.052. Kalibracja lekko poprawiła NLL i Brier score:

Etap	NLL	Brier	ECE
przed kalibracją	0.6018	0.3568	0.0253
po kalibracji	0.6015	0.3564	0.0308

Klasy decyzyjne nie zmieniły się, ale prawdopodobieństwa zostały delikatnie wygładzone. Diagram wiarygodności zapisano w `outputs/figures/reliability_diagram.png`.

7. Niepewność

Dla każdej próbki testowej policzono:

- maksymalne prawdopodobieństwo,
- entropie rozkładu klas,
- margines między top-1 i top-2.

Zapisano przypadki:

- `outputs/tables/most_confident_correct.csv`,
- `outputs/tables/most_uncertain_correct.csv`,
- `outputs/tables/most_uncertain_wrong.csv`.

Te grupy zostały potem wykorzystane do lokalnych wyjaśnień LIME.

8. Permutation Feature Importance

PFI policzono osobno dla train i test, zgodnie z wymaganiem. Najważniejsze cechy testowe to m.in. X16, X24, X106, X68, X11, X10, X7, X12 i X87.

PFI segmentowe dla test wskazuje następującą kolejność fragmentów sygnału:

Segment	Suma ważności
X1-X30	0.659
X61-X90	0.558
X91-X120	0.533
X31-X60	0.527
X121-X150	0.523
X151-X178	0.493

Wniosek: model korzysta z informacji rozłożonej po całym sygnale, ale początkowy fragment X1-X30 jest szczególnie istotny w zbiorze testowym.

9. LIME

LIME uruchomiono globalnie przez agregację lokalnych wyjaśnień oraz lokalnie dla przypadków pewnych i niepewnych. Globalnie najwyżej pojawiły się cechy z początku sygnału, m.in. X7, X4, X1, X9, X8, X2, X3.

Porównanie z PFI jest spójne: obie metody wskazują na duże znaczenie wczesnych punktów czasowych. PFI dodatkowo pokazuje istotność późniejszych punktów, np. X106 i segmentów środkowych.

Lokalne wyjaśnienia HTML zapisano w `outputs/lime/`. Dla przypadków pewnych wagi LIME zwykle koncentrują się na kilku cechach wspierających jedną klasę.

Dla przypadków niepewnych widac słabszy margines decyzji i cechy wspierające konkurencyjne klasy.

10. Ograniczenia

Projekt ma charakter edukacyjny i nie jest systemem diagnostycznym. Random split może mieszać próbki pochodzące z podobnych źródeł, ponieważ publiczny CSV nie

udostępnia pełnej informacji o pacjencie/sesji. Interpretacja cech X1-X178 dotyczy punktów czasowych sygnału, a nie bezpośrednio struktur biologicznych.


11. Reprodukowalność

Główny pipeline:


```
python -m src.run_pipeline --config configs/config.yaml
```

Najważniejsze wyniki są w `outputs/`, a konfiguracja w `configs/config.yaml`.


Confusion matrix



Reliability diagram



Segment-level PFI on test set



Global LIME importance

